DESAFIO DE ANÁLISE E MODELAGEM DE DADOS

Estudo de caso: previsão do desempenho escolar

1. Objetivo

O desafio consiste em organizar, tratar e analisar dados referentes a escolas e estudantes, desenvolvendo uma abordagem de modelagem capaz de prever o resultado dos alunos no exame normalizado (normexam) a partir de características individuais e institucionais.

Além da tarefa preditiva, a análise deve investigar qual tipo de escola — mista, exclusivamente masculina ou exclusivamente feminina — apresenta maior eficiência na formação de seus alunos, utilizando os resultados do exame normalizado como referência. A conclusão deve ser sustentada pelos resultados e parâmetros do modelo.

2. Base de dados

A base de dados é composta por quatro arquivos, separados de acordo com o tipo de variável e a unidade de observação:

Arquivo	Conteúdo
cat school data.csv	Variáveis categóricas referentes às escolas.
num school data.csv	Variáveis numéricas referentes às escolas.
cat student data.csv	Variáveis categóricas referentes aos estudantes.
num student data.csv	Variáveis numéricas referentes aos estudantes.

As bases de estudantes e escolas devem ser integradas por meio da variável school. Os identificadores de estudantes (student) são únicos dentro de cada escola.

A base foi descrita no material original como proveniente de um curso de modelagem da Universidade Harvard.

3. Atividades propostas

- Inspecionar os arquivos e compreender a estrutura das variáveis disponíveis.
- Realizar o tratamento dos dados, identificando e lidando com inconsistências e valores ausentes, quando existentes.
- Integrar as informações de estudantes e escolas utilizando as chaves de identificação fornecidas.
- Explorar as relações entre as características dos alunos, das escolas e o resultado normexam.
- Construir e avaliar um ou mais modelos para prever o desempenho no exame normalizado.
- Investigar as diferenças de desempenho entre escolas mistas, masculinas e femininas, justificando a conclusão com os resultados da modelagem.

4. Entregáveis e apresentação dos resultados

O trabalho deve apresentar o código utilizado no tratamento dos dados e na modelagem, com organização e identificação adequadas. A análise pode ser desenvolvida em Python ou R.

Ao final do código ou relatório, deve ser apresentada uma conclusão breve, de aproximadamente um parágrafo, respondendo qual tipo de escola aparenta ser mais eficiente na formação dos alunos. A justificativa deve estar relacionada aos parâmetros e resultados obtidos pelo modelo.

Caso não seja possível concluir todas as etapas, é válida a apresentação de uma análise parcial, acompanhada da descrição das etapas realizadas e das dificuldades encontradas.

5. Competências trabalhadas

O estudo permite exercitar organização de código, manipulação e integração de bases de dados, análise exploratória, preparação de variáveis, modelagem preditiva e interpretação crítica de resultados em um problema aplicado de Ciência de Dados.