Relatório desafio Murabei

Murabei Data Science

Jhonatan Bryan Lemmo Rodrigues

Sumário

1 Resumo **3**

2 Objetivos **3**

3 Base de Dados **3**

3.1 Tratamento de dados 4

4 Análise estatística **6**

4.1 Distribuições 6

4.2 P-teste 7

4.3 Correlação entre variáveis 8

4.4 Comparação entre sexos 9

5 Machine learning **9**

5.1 Modelagem 10

6 Resultados e Discussão **11**

7 Conclusão e agradecimentos **11**

1 Resumo

Analisamos dados de escolas e alunos a fim de saber qual tipo de escola é mais eficiente, a partir de cálculos estatísticos e regressão linear, chegamos a conclusão que a escola feminina é a mais eficiente

2 Objetivos

Nesse desafio tenho como objetivo prever o resultado do exame de acordo com as características da escola e responder qual tipo de escola (gênero misto, só de homens ou só de mulheres) é mais eficiente para formação de seus alunos parar tal fim usamos:

- Tratamento do conjunto de dados
- Identificar padrões e correlações
- Fazer analise estatística
- Construir e avaliar modelos preditivos.

3 Base de Dados

A base de dados fornecida foi extraída do curso de modelagem de Harvard 1 e está organizada em quatro arquivos diferentes:

cat school data.csv Variáveis categóricas que são aplicadas às escolas.

num school data.csv Variáveis numéricas que são aplicadas às escolas.

cat student data.csv Variáveis categóricas que são aplicadas aos estudantes.

num student data.csv Variáveis numéricas que são aplicadas aos estudantes.

Os dados das diferentes bases são descritos abaixo. As tabelas de estudante e escola são cruzadas através do campo school, os ids dos estudantes (student) são únicos para cada escola.

Cada arquivo esta no formato

Precisamos juntar Variável-valor de uma maneira eficiente e tomar cuidado com valores nulos, ou seja fazer um tratamento de dados

Variável	Descrição	Tipo
school	ID da escola	Categórica
normexam	Nota do exame normalizada	Numérica
schgend	Gênero da escola	Categórica
schavg	Média da nota de entrada da escola	Numérica
vr	Faixa da pontuação de Raciocínio Verbal (VR) na entrada	Numérica
intake	Faixa de nota de entrada do estudante	Categórica
standLRT	Pontuação padronizada do teste LR	Numérica
sex	Sexo do estudante (F ou M)	Categórica
type	Tipo de escola	Categórica
student	ID do estudante (dentro da escola)	Categórica

Tabela 1: Descrição das variáveis com tipo

ID	Variável	valor

3.1 Tratamento de dados

Primeiramente para os dados de cada escola, juntamos os aquivos categóricos e os numéricos em um único dataframe e pivoteamos, para cada variável distinta, virar uma coluna no dataframe da forma

school	type	schgend	schavg

Não havia valores duplicados nem nulos, mas usamos a função só para ter a certeza. É importante que a variável numérica esteja no tipo correto, o python funciona com separação decimal com ponto (.) ao invés do padrão brasileiro que é a virgula (,), assim não sendo reconhecida como uma variável de ponto flutuante (float), precisamos usar um comando para converter

```
df_school = pd.concat([
    pd.read_csv('/num_school_data.csv', sep=";"),
    pd.read_csv('/cat_school_data.csv', sep=";")
], ignore_index=True)

df_school = df_school.drop_duplicates().dropna()

df_school = df_school.pivot(
    index='school',
    columns='variable',
    values='value'
)[['type','schgend','schavg']]

df_school['schavg'] = df_school['schavg'].str.replace(',', '.').astype(float)
```

Para os estudantes fizemos a mesma logica, porem com o cuidado de que o id de cada aluno é a escola junto com seu numero de estudante, pois para cada escola tem um único aluno com tal identificação, caso o aluno tenha duplicatas removemos esse aluno do dataframe, também removemos todos os dados onde nossa variável de interesse (normexam) é nula.

```
df_student = pd.concat([
    pd.read_csv('/num_student_data.csv', sep=";"),
    pd.read_csv('/cat_student_data.csv', sep=";")
], ignore_index=True).drop_duplicates().dropna()

# Remover alunos  duplicados
duplicates = df_student.groupby(['school', 'student']).filter(lambda x: len(x) > 5)
df_student = df_student[~df_student.set_index(['school',
↪  'student']).index.isin(duplicates.set_index(['school', 'student']).index)]

# Pivotar para formato wide
df_student = (
    df_student
    .pivot_table(index=['school','student'], columns='variable', values='value',
    ↪  aggfunc='first')
    .reset_index()
)

df_student = df_student.dropna(subset=['normexam']).reset_index(drop=True)

# parce para float
df_student['normexam'] = df_student['normexam'].str.replace(',', '.').astype(float)
df_student['standLRT'] = df_student['standLRT'].str.replace(',', '.').astype(float)
```

Para ter uma unica tabela com todos dados que temos pegamos as informações da escola e colocamos na tabela de alunos ou seja cada aluno vai receber a informação do tipo que é sua escola (type) o genero da escola (schgend) e a média da nota de entrada da escola (schavg), ficando no formato

student	school	type	schgend	schavg	sex	vr	standLRT	normexam

```
df_student['schgend'] = df_student.school.map(df_school['schgend'])
df_student['type'] = df_student.school.map(df_school['type'])
df_student['schavg'] = df_student.school.map(df_school['schavg'])
```

Ainda existe um problema, há dados faltantes em algumas colunas, vamos tentar preencher os possíveis, com os dados de que já temos, se o aluno estuda em uma escola masculina ja sabemos que é um homem, o mesmo vale para feminina, e o vr é o mesmo para todos os estudantes de uma mesma escola, assim preenchemos alguns dados faltantes

```
#preenche null sex com base no tipo de escola
df_student['sex'] = df_student['sex'].fillna(df_student['schgend'].map({'girls':'F',
↪  'boys':'M'}))

#preenche null vr com base na escola
df_student['vr'] =
↪  df_student['vr'].fillna(df_student.groupby('school')['vr'].transform('first'))
```

Com todos dados preparados podemos fazer nossa analise estatística.

4 Análise estatística

Queremos analisar os diferentes tipos de escolas e relacioná-las a sua nota no exame temos a distribuição de alunos para cada tipo de escola

Tipo de Escola	Escolas	Escolas %	Alunos	Alunos %
Mista	35	54%	2096	53%
Feminina	20	31%	1339	34%
Masculina	10	15%	501	13%
Total	65	100%	3936	100%

Dentre as escolas mistas temos 1045 homens e 998 e 53 não informados.

4.1 Distribuições

Vamos analisar a distribuição de alunos de cada escola em relação a nota do exame

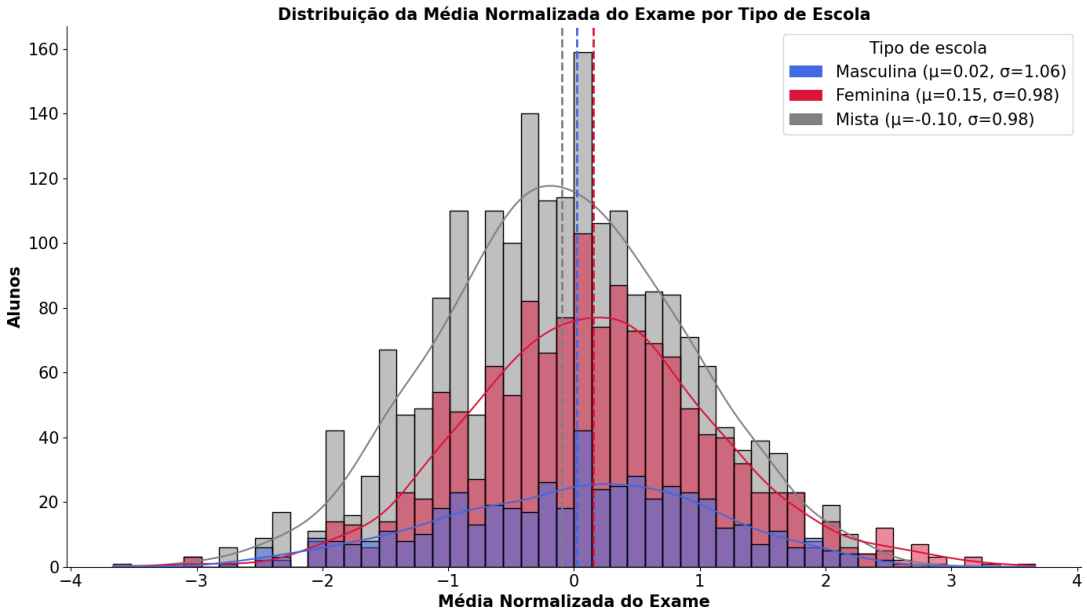


Figura 1: Distribuição da media do exame por aluno de cada tipo de escola, com as medias e desvio padrão, com 52 intervalos

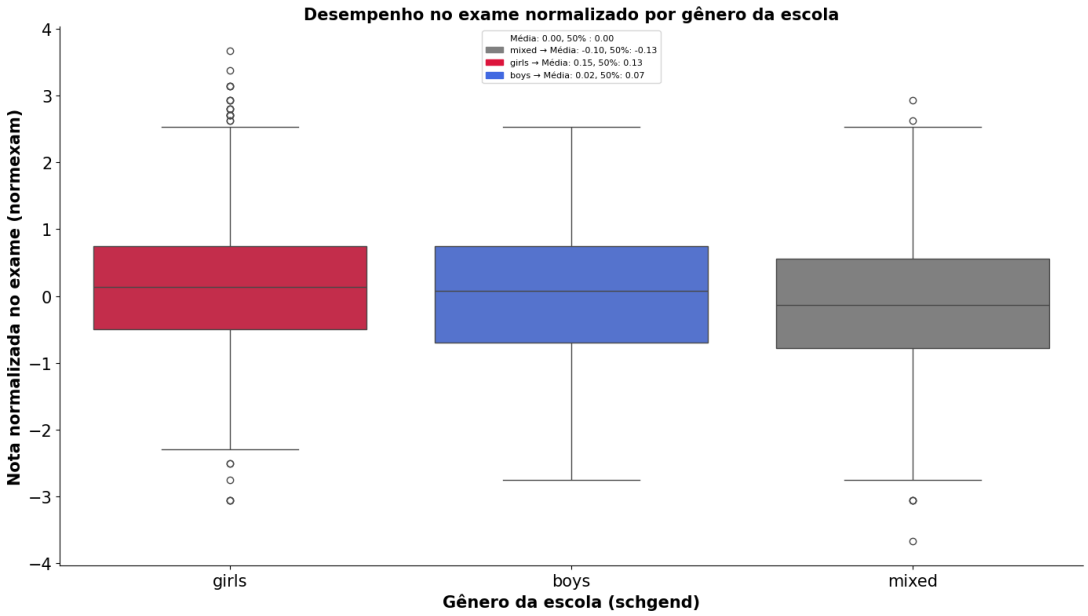


Figura 2: box plot dos tipos

Analisando o gráfico da figura 1 e 2 percebemos se aproximam de uma gaussiana e tem um leve deslocamento da distribuição para direita da escola feminina, masculina, e mista, o que bate com o a media, temos evidencias de que a escola feminina tem maior desempenho, e a mista a pior, mas para afirmar precisamos examinar mais afundo os outros parâmetros. Também não podemos descartar a priori que essa distribuição é somente um erro estatístico e não há diferença entre os tipo, para isso podemos realizar o p-teste

4.2 P-teste

O **valor-p** representa a probabilidade de observar uma diferença igual ou maior que a observada, caso as médias dos grupos sejam realmente iguais (hipótese nula verdadeira).

$$p = P(T \geq |t_{\text{observado}}|)$$

Interpretação típica:

- $p < 0.05$: diferença estatisticamente significativa (rejeita-se a hipótese nula);
- $p \geq 0.05$: diferença não significativa (não há evidência suficiente).

Seja a hipótese nula H_0 = não ha diferença real entre as escolas com base no exame

Tabela 2: Resultados dos P-teste entre tipos de escola

Comparação	**Estatística t**	**Valor p**
Mista × Feminina	-7.287	0.0000
Mista × Masculina	-2.265	0.0238
Feminina × Masculina	2.452	0.0144

Portanto como p<0.05 em todos os casos podemos rejeitar a hipótese de que os tipos são equivalentes. Agora veremos como as variáveis se relacionam.

4.3 Correlação entre variáveis

Vamos agora ver como se a nota do exame se comporta com a nota de entrada, com o teste de raciocínio logico

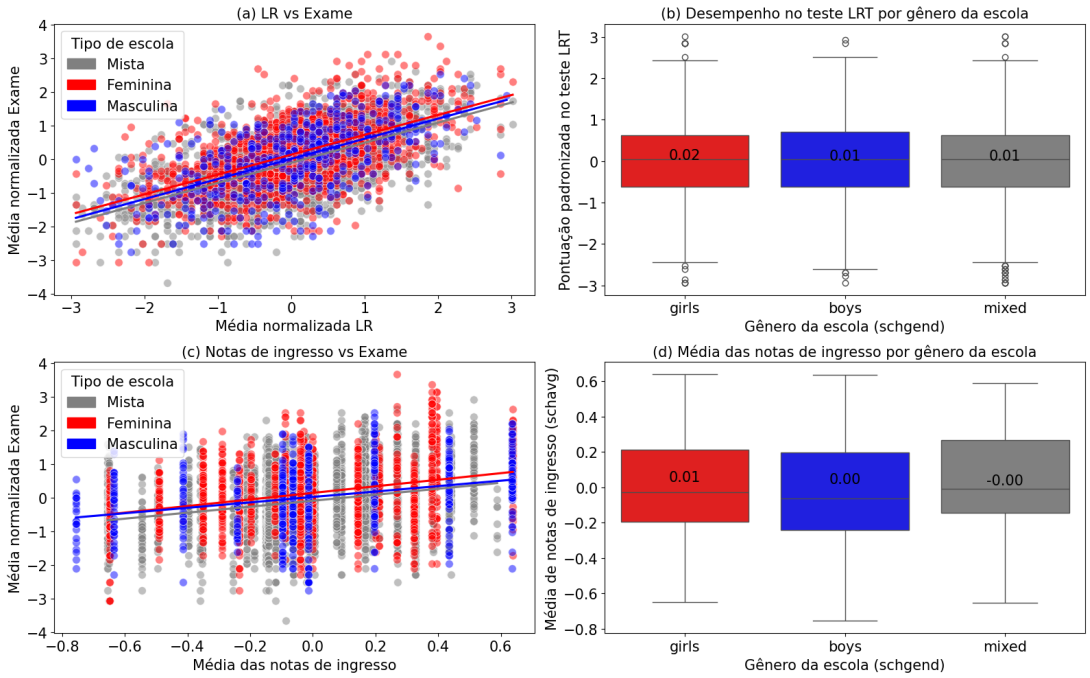


Figura 3: relação das variáveis e a media por gênero da escola

Vimos na figura 3 uma linearidade positiva dos dados, ou seja quem foi melhor nos testes iniciais em media vai melhor no exame. Vimos que a escola feminina tem uma media de resultado nesses testes um pouco maior o que pode explicar por que dela ter os melhores resultados nos exames mas a diferencia é pouca comparado a diferença da media nos exames.

Outro questionamento que surge é sera que a escola feminina é melhor ou simplesmente as mulheres no geral tem melhores notas

4.4 Comparação entre sexos

Vamos comparar a distribuição de sexos

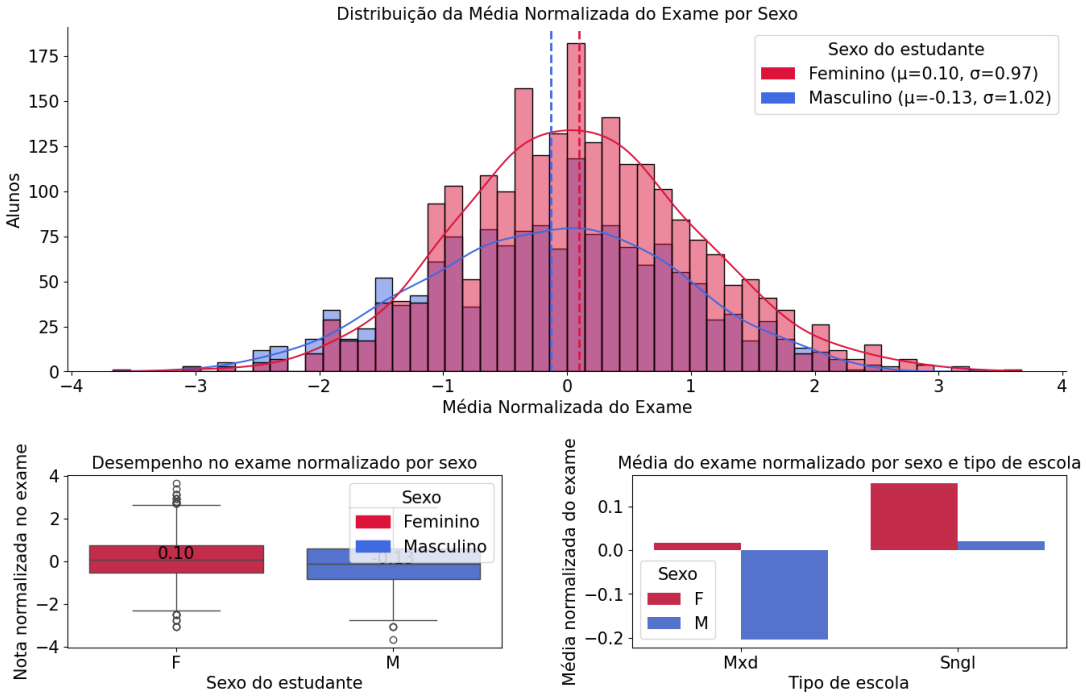


Figura 4: Distribuição de sexos

Vimos na figura 4 que sim há uma diferença entre os sexos, e que as mulheres se destacam em relação aos homens, curiosamente homens em escolas mistas tem um desempenho muito abaixo de homens em escolas de sexo único, enquanto, mulheres tem menos desempenho em escolas mistas mas nem tanto quando os homens.

De toda forma escolas mistas apresentam um melhor desempenho no geral, podemos modelar usando machine learning para poder prever o resultado do exame dado as variáveis e conferir se bate com a estatistica

5 Machine learning

Para criação do modelo foi necessário transformar as variáveis categóricas em valores, transformamos 'M' em 0 e 'F' em 1 vr e intake indo de -1 a 1 e os tipos de escola foi separado em 'schgend_girls' e 'schgend_mixed' com valores booleanos. Também foi excluido as colunas 'student','school','type' pois não são importantes para o modelo.

```
df_student = df_student.drop(['student','school','type'],axis=1)

df_student = df_student.dropna().reset_index(drop=True)

ordem = {
    'bottom 25%': -1,
    'mid 50%': 0,
    'top 25%': 1,
}

df_student['intake'] = df_student['intake'].map(ordem)
df_student['vr'] = df_student['vr'].map(ordem)
df_student['sex'] = df_student['sex'].map({'F': 1, 'M': 0})
df_student = pd.get_dummies(df_student, columns=['schgend'], drop_first=True)
df_student =
```

5.1 Modelagem

Como os dados analisados aparentam ter comportamento linear usei um modelo linear para o aprendizado undo 20% dos dados para teste e o restante para treinar

```
variaveis = ["schgend_girls", "schgend_mixed", "schavg", "sex", "intake", "vr",
↪  "standLRT"]
X = df_student[variaveis]
y = df_student["normexam"]

# Dividir treino/teste
X_treino, X_teste, y_treino, y_teste = train_test_split(X, y, test_size=0.2,
↪  random_state=42)
lin_model = LinearRegression()

lin_model.fit(X_treino, y_treino)
```

O modelo foi treinado com $R^2 = 0.416$ e RMSE $= 0.58$, o que significa que O modelo consegue explicar cerca de 42% da variação dos dados.

Temos os pesos de cada variavel como

Variável	**Peso**
schgend_girls	0.0225
schgend_mixed	-0.1536
schavg	0.5028
sex	0.1125
intake	-0.3788
vr	-0.0914
standLRT	0.3866

Tabela 3: Pesos das variáveis do modelo

Como prevemos estatisticamente por a escola é mista ela ter peso negativo, significa que alunos de escolas de sexo único contribuem mais para o acréscimo da nota do exame, sendo de escolas femininas um peso positivo contribuindo para aumentar a nota, notasse que alunas no sexo feminino contribuem bastante, mas não tanto quando o tipo de escola. É também notável que quem tirou as maiores notas nos exames iniciais tiram notas melhores nos exames.

6 Resultados e Discussão

Através da analise estatística e do modelo de machine learn que escolas femininas tem maiores chances de tirarem maiores notas no exame, seguido das escolas masculinas, e por fim escolas mistas.

Porém pela baixa quantidade de dados pode tornar essa analise equivocada e não refletir a realidade.

7 Conclusão e agradecimentos

Os dados apontam que escolas femininas tem maiores desempenhos em exames.

Gostaria de agradecer a Murabei pela oportunidade e pelo desafio, aprendi muito no processo e espero conseguir a vaga para continuar o aprendizado.